

# Conceitos Sobre Distribuições de Probabilidade

Gabriel D'assumpção de Carvalho

2025-08-01

## Contents

<b>1</b>	<b>Introdução</b>	<b>2</b>
<b>2</b>	<b>Distribuições Discretas</b>	<b>2</b>
2.1	Distribuição de Bernoulli . . . . .	2
2.2	Distribuição Binomial . . . . .	3
2.3	Distribuição Multinomial . . . . .	5
2.4	Distribuição de Poisson . . . . .	9
2.5	Distribuição Geométrica . . . . .	11
2.6	Distribuição Hipergeométrica . . . . .	13
<b>3</b>	<b>Distribuições Contínuas</b>	<b>13</b>
3.1	Distribuição Exponencial . . . . .	14
3.2	Distribuição Gamma . . . . .	15

## 1 Introdução

Neste relatório, abordamos os principais conceitos relacionados às seguintes distribuições de probabilidade: Bernoulli, Binomial, Multinomial, Poisson, Exponencial, Geométrica, Hipergeométrica, Gama e Weibull. Essas distribuições são fundamentais para a modelagem estatística, especialmente em contextos de análise de sobrevivência, pois permitem descrever a probabilidade de ocorrência de eventos discretos (como sucesso, falha, etc.) e contínuos (como tempo até a falha ou tempo de vida útil de um sistema).

Neste estudo, geraremos amostras com 1000 observações de cada uma dessas distribuições. Em seguida, construiremos gráficos de barras para variáveis discretas e histogramas para variáveis contínuas, a fim de visualizar o comportamento de suas respectivas probabilidades.

```
# Configuração de reprodutibilidade  
n <- 1000  
set.seed(42)
```

## 2 Distribuições Discretas

Distribuições discretas descrevem variáveis aleatórias que podem assumir valores finitos ou contáveis. Abaixo, exploramos algumas das distribuições discretas mais utilizadas na prática estatística.

### 2.1 Distribuição de Bernoulli

A distribuição de Bernoulli é uma das mais importantes distribuições de probabilidade. Qualquer situação que envolva apenas dois desfechos possíveis pode ser modelada como uma variável de Bernoulli. Os dois resultados possíveis são: sucesso (1) ou fracasso (0). A probabilidade de sucesso é denotada por  $p$  e a de fracasso por  $q = 1 - p$ .

A função de massa de probabilidade (FMP) da distribuição de Bernoulli é dada por:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

Onde  $X$  representa a variável aleatória que indica o resultado do experimento.

#### 2.1.1 Esperança

A esperança da variável  $X_i$  é dada por:

$$E(X) = \mathbb{P}(X = 1) \cdot 1 + \mathbb{P}(X = 0) \cdot 0 = p$$

#### 2.1.2 Variância

Utilizando a identidade  $\text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2$ , temos:

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = p(1 - p) = pq$$

Sendo:

- $E(X)$ : esperança (média) da variável aleatória  $X$ ;
- $\text{Var}(X)$ : variância de  $X$ ;
- $p$ : probabilidade de sucesso;
- $q$ : probabilidade de fracasso.

### 2.1.3 Exemplo

```
p <- 0.7
bernoulli <- rbinom(n, 1, p)

barplot(table(bernoulli),
  main = "Distribuição Bernoulli (p = 0.7)",
  names.arg = c("0", "1"),
  col = c("#ff0000", "#55a802"),
  ylab = "Frequência",
  xlab = "Valor"
)
```




Figure 1: Distribuição de Bernoulli

```
print(paste("Esperança:", mean(bernoulli), " | ", "p = ", p))

## [1] "Esperança: 0.707 | p = 0.7"

print(paste("Variância:", round(var(bernoulli), 4), " | ", "p * q = ", p * (1 - p)))

## [1] "Variância: 0.2074 | p * q = 0.21"
```

Podemos observar que a média e a variância empíricas da amostra seguem de perto os valores teóricos  $E(X) = p$  e  $\text{Var}(X) = pq$ , confirmando a adequação da distribuição.

## 2.2 Distribuição Binomial

A distribuição binomial generaliza a Bernoulli para  $n$  repetições independentes do mesmo experimento. Cada tentativa tem probabilidade de sucesso  $p$  e fracasso  $q = 1 - p$ . A variável aleatória  $X$  representa o número de sucessos em  $n$  tentativas.

A função de massa de probabilidade é dada por:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

Onde:

- $n$ : número total de tentativas;
- $k$ : número de sucessos;
- $\binom{n}{k}$ : coeficiente binomial, que representa o número de combinações de  $n$  termos,  $k$  a  $k$ .

Nota-se que quando  $n = 1$ , a distribuição binomial se reduz à distribuição de Bernoulli. Por isso, foi utilizado `rbinom(n, 1, p)` no exemplo 2.1.3.

### 2.2.1 Esperança

A esperança da variável  $X_i$  é dada por:

$$\begin{aligned} E(X^i) &= \sum_{k=0}^n k^i \cdot \binom{n}{k} p^k \cdot (1-p)^{n-k} = \sum_{k=0}^n k \cdot k^{i-1} \cdot \binom{n}{k} \cdot p \cdot p^{k-1} \cdot (1-p)^{n-k} \\ &= \sum_{k=0}^n \cancel{k} \cdot k^{i-1} \cdot \frac{n \cdot (n-1)!}{\cancel{k} \cdot (k-1)! \cdot (n-k)!} \cdot p \cdot p^{k-1} \cdot (1-p)^{n-k} = n \cdot p \sum_{k=0}^n k^{i-1} \cdot \frac{(n-1)!}{(k-1)! \cdot (n-k)!} \cdot p^{k-1} \cdot (1-p)^{n-k} \end{aligned}$$

Aplicando a substituição de índice:

$$k = j + 1 \Rightarrow k - 1 = j$$

Obtemos:

$$E(X^i) = n \cdot p \sum_{j=0}^{n-1} (j+1)^{i-1} \cdot \frac{(n-1)!}{j! \cdot (n-j-1)!} \cdot p^j \cdot (1-p)^{n-j-1} = n \cdot p \sum_{j=0}^{n-1} (j+1)^{i-1} \cdot \binom{n-1}{j} \cdot p^j \cdot (1-p)^{n-j-1}$$

Reconhecendo a estrutura esperada de um momento da distribuição binomial de ordem  $n-1$ , temos:

$$E(X^i) = n \cdot p \cdot E[(j+1)^{i-1}], \quad \text{onde } j \sim \text{Binomial}(n-1, p)$$

Portanto, ao aplicar a propriedade recursiva para o primeiro momento ( $i = 1$ ), temos:

$$E(X) = n \cdot p \cdot E(X^0) = n \cdot p \cdot 1 = n \cdot p$$

### 2.2.2 Variância

Utilizando a identidade  $\text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2$ , temos:

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 = n \cdot p \cdot E[(j+1)^{2-1}] - n^2 \cdot p^2 = n \cdot p \cdot ((n-1) \cdot p + 1) - n^2 \cdot p^2 \\ &= n \cdot p \cdot (n \cdot p - p + 1) - n^2 \cdot p^2 = \cancel{n^2} \cdot \cancel{p^2} - n \cdot p^2 + n \cdot p - \cancel{n^2} \cdot \cancel{p^2} = n \cdot p \cdot (1-p) = n \cdot p \cdot q \end{aligned}$$

### 2.2.3 Exemplo

```
k <- 100

binomial <- rbinom(n, k, 0.7)

barplot(
  table(binomial),
  main = "Distribuição Binomial (n = 1000, k = 100, p = 0.7)",
  col = "#55a802",
  ylab = "Frequência",
  xlab = "Número de Sucessos"
)
```




Figure 2: Distribuição Binomial

```
print(paste("Esperança:", mean(binomial), " | ", "k * p = ", k * p))

## [1] "Esperança: 70.24 | k * p = 70"

print(paste("Variância:", round(var(binomial), 4), " | ", "k * p * q = ", k * p * (1 -
p)))

## [1] "Variância: 21.2917 | k * p * q = 21"
```

Com isso, podemos ver que a média e a variância empírica da amostra de uma variável aleatória que segue uma distribuição binomial com parâmetros  $n$  e  $p$  se aproximam dos valores teóricos  $E(X) = n \cdot p$  e  $\text{Var}(X) = n \cdot p \cdot q$ , confirmando as propriedades demonstradas.

## 2.3 Distribuição Multinomial

A distribuição multinomial é uma generalização da distribuição binomial para experimentos com mais de dois possíveis resultados. Ela é usada quando realizamos  $n$  experimentos independentes, cada um resultando em

exatamente uma das  $k$  categorias possíveis. Cada categoria  $i = 1, 2, \dots, k$  tem uma probabilidade associada  $p_i$ , com  $\sum_{i=1}^k p_i = 1$ . A função de massa de probabilidade da distribuição é dada por:

$$P(X_1 = n_1, \dots, X_k = n_k) = \binom{n}{n_1, n_2, \dots, n_k} \cdot p_1^{n_1} \cdots p_k^{n_k}$$

Podemos expandir o coeficiente multinomial como:

$$= \frac{n!}{n_1! \cdot (n - n_1)!} \cdot \frac{(n - n_1)!}{n_2! \cdot (n - n_1 - n_2)!} \cdots \frac{(n - n_1 - \dots - n_{k-1})!}{n_k! \cdot 0!} \cdot p_1^{n_1} \cdots p_k^{n_k}$$

Resultando em:

$$= \frac{n!}{n_1! \cdots n_k!} \cdot p_1^{n_1} \cdots p_k^{n_k}$$

Onde:

- $X_i$ : número de ocorrências da categoria  $i$ ;
- $n$ : número total de experimentos;
- $n_i$ : número de vezes que a categoria  $i$  ocorreu (ou seja,  $X_i = n_i$ );
- $p_i$ : probabilidade de ocorrência da categoria  $i$ .

### 2.3.1 Esperança

A esperança da variável  $X_i$  é dada por:

$$E(X_i) = \sum_{x_1 + \dots + x_k = n} X_i \cdot \frac{n!}{x_1! \cdots x_k!} \cdot p_1^{x_1} \cdots p_k^{x_k}$$

Aplicando a manipulação:

$$E(X_i) = n \cdot p_i \cdot \sum \frac{(n-1)!}{(x_1 - \delta_{1i})! \cdots (x_k - \delta_{ki})!} \cdot p_1^{x_1 - \delta_{1i}} \cdots p_k^{x_k - \delta_{ki}}, \quad \delta_{ji} = \begin{cases} 1, & \text{se } j = i \\ 0, & \text{caso contrário} \end{cases}$$

Essa soma corresponde a uma distribuição multinomial de ordem  $(n-1)$  e soma 1:

$$\Rightarrow E(X_i) = n \cdot p_i$$

### 2.3.2 Variância

Utilizando a identidade  $\text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2$ , temos:

$$E(X_i^2) = E(X_i(X_i - 1)) + E(X_i)$$

Sabendo que:

$$E(X_i(X_i - 1)) = n(n-1)p_i^2 \quad \text{e} \quad E(X_i) = np_i$$

Substituimos:

$$\begin{aligned}\text{Var}(X_i) &= n(n-1)p_i^2 + np_i - (np_i)^2 = n^2p_i^2 - np_i^2 + np_i - n^2p_i^2 \\ &= -np_i^2 + np_i = np_i(1 - p_i)\end{aligned}$$

Logo, a variância da variável  $X_i$  na distribuição multinomial é:

$$\text{Var}(X_i) = np_i(1 - p_i)$$

### 2.3.3 Exemplo

```
class <- 4
ps <- c(p, rep((1 - p) / (class - 1), class - 1))
multnom <- rmultinom(n, size = k, prob = ps)
frequencias <- rowSums(multnom)
```

```

barplot(
  frequencias,
  names.arg = paste("Classe", 1:class),
  col = colorRampPalette(c("#b2df8a", "#33a02c"))(class),
  main = paste("Distribuição Multinomial: n =", n, ", size =", k, "class =", class),
  cex.main = 0.9,
  xlab = "Classe",
  ylab = "Frequência"
)

```




Figure 3: Distribuição Multinomial

```

E_empirica <- rowSums(multnom) / n
E_teorica <- k * ps

data.frame(
  Classe = paste0("Classe ", 1:length(ps)),
  `E(empírica)` = round(E_empirica, 3),
  `E(teórica)` = round(E_teorica, 3)
)

```

```

##      Classe E.empírica E.teórica
## 1 Classe 1      69.929         70
## 2 Classe 2      10.101          10
## 3 Classe 3       9.999          10
## 4 Classe 4       9.971          10

```

Dado um experimento multinomial com  $n = 1000$ , tamanho de ensaio  $k = 100$ , probabilidade da primeira classe  $p_1 = 0.7$  e as probabilidades restantes definidas como  $p_i = \frac{1-p_1}{\text{número de classes}-1}$ , totalizando 4 classes, observa-se que a média empírica se aproxima da média teórica, confirmando assim as propriedades esperadas da distribuição multinomial.



## 2.4 Distribuição de Poisson

A distribuição de poisson é uma distribuição discreta que modela o número de eventos que ocorrem em um intervalo fixo de tempo, tendo uma taxa média de ocorrência  $\lambda$ , constante e independente do tempo. Com isso, a função de massa de probabilidade é dada por:

$$P(X = k) = \frac{\lambda^k \cdot e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

Onde:

- $k$ : Valor que a variável aleatória  $X$  pode assumir (número de eventos);
- $\lambda$ : Taxa média de ocorrência de eventos no intervalo considerado;
- $e$ : Base do logaritmo natural, aproximadamente 2.71828.

### 2.4.1 Esperança

A esperança da variável  $X$  é dada por:

$$\begin{aligned} E(X) &= \sum_{k=0}^{\infty} k \cdot P(X = k) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k \cdot e^{-\lambda}}{k!} \\ &= \sum_{k=1}^{\infty} \lambda \cdot \cancel{k} \cdot \frac{\lambda^{k-1} \cdot e^{-\lambda}}{\cancel{k} \cdot (k-1)!} = \lambda \cdot e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda \cdot e^{-\lambda} \cdot \left[ \frac{\lambda^0}{0!} + \frac{\lambda^1}{1!} + \frac{\lambda^2}{2!} + \dots \right] \xrightarrow{e^\lambda} \lambda \end{aligned}$$

### 2.4.2 Variância

A variância da variável que segue a distribuição de Poisson é dada por:

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 = \sum_{k=0}^{\infty} k^2 \cdot P(X = k) - \lambda^2 \\ E(X^2) &= 1^2 \left[ \frac{e^{-\lambda} \cdot \lambda^1}{1!} \right] + 2^2 \left[ \frac{e^{-\lambda} \cdot \lambda^2}{2!} \right] + 3^2 \left[ \frac{e^{-\lambda} \cdot \lambda^3}{3!} \right] + \dots + n^2 \left[ \frac{e^{-\lambda} \cdot \lambda^n}{n!} \right] + \dots \\ &= e^{-\lambda} \cdot \lambda \left[ 1 + 2 \cdot \lambda + 3 \cdot \frac{\lambda^2}{2!} + \dots + n \cdot \frac{\lambda^{n-1}}{(n-1)!} + \dots \right] \\ &= e^{-\lambda} \cdot \lambda \cdot \sum_{n=1}^{\infty} n \cdot \frac{\lambda^{n-1}}{(n-1)!}, \text{ onde } n-1 = k \text{ e } n = k+1 \\ &= e^{-\lambda} \cdot \lambda \cdot \left[ 0 + \frac{\lambda}{1!} + \frac{2 \cdot \lambda^2}{2!} + \frac{3 \cdot \lambda^3}{3!} + \dots + e^\lambda \right] \end{aligned}$$

$$= e^{-\lambda} \cdot \lambda \cdot \left[ \lambda \left( 1 + \frac{\lambda}{1!} + \frac{\lambda^2}{2!} + \cdots + \frac{\lambda^{k-1}}{(k-1)!} \right) + e^{\lambda} \right] = e^{-\lambda} \cdot \lambda \cdot [\lambda \cdot e^{\lambda} + e^{\lambda}] = e^0 \cdot \lambda^2 + e^0 \cdot \lambda = \lambda^2 + \lambda$$

$$\text{Var}(X) = \cancel{\lambda^2} + \lambda - \cancel{\lambda^2} = \lambda$$

### 2.4.3 Exemplo

```
lambda <- 5
poisson <- rpois(n, lambda)

barplot(
  table(poisson),
  main = paste("Distribuição de Poisson (lambda =", lambda, ")"),
  col = "#55a802",
  ylab = "Frequência",
  xlab = "Número de Eventos"
)
```




Figure 4: Distribuição de Poisson

```
print(paste("Esperança:", mean(poisson), " | ", "lambda = ", lambda))

## [1] "Esperança: 5.019 | lambda = 5"

print(paste("Variância:", round(var(poisson), 4), " | ", "lambda = ", lambda))

## [1] "Variância: 4.8395 | lambda = 5"
```

Portanto, podemos observar que a média e a variância empírica da amostra de uma variável aleatória que segue uma distribuição de Poisson com parâmetro  $\lambda$  se aproximam dos valores teóricos  $E(X) = \lambda$  e  $\text{Var}(X) = \lambda$ , confirmando as propriedades esperadas da distribuição.

## 2.5 Distribuição Geométrica

A distribuição geométrica modela o número de tentativas até a ocorrência do primeiro sucesso em uma sequência de experimentos de Bernoulli independentes. Sua função de massa de probabilidade é dada por:

$$P(X = k) = (1 - p)^{k-1} \cdot p, \quad k = 1, 2, \dots$$

### 2.5.1 Esperança

A esperança da variável aleatória  $X$  é calculada como:

$$E(X) = \sum_{k=1}^{\infty} k \cdot P(X = k) = \sum_{k=1}^{\infty} k \cdot (1 - p)^{k-1} \cdot p = p \cdot \sum_{k=1}^{\infty} k \cdot (1 - p)^{k-1}$$

Denotando  $q = 1 - p$ , reconhecemos que a soma é uma série geométrica diferenciada, cuja soma é:

$$\sum_{k=1}^{\infty} k \cdot q^{k-1} = \frac{1}{(1 - q)^2}$$

Como  $1 - q = p$ , temos:

$$E(X) = \cancel{p} \cdot \frac{1}{\cancel{p^2}} = \frac{1}{p}$$

### 2.5.2 Variância

A variância é obtida por:

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = E[X(X - 1)] + E(X) - \left(\frac{1}{p}\right)^2$$

onde:

$$E[X(X - 1)] = \sum_{k=2}^{\infty} k(k - 1) \cdot q^{k-1} \cdot p$$

Utilizando as propriedades das séries geométricas diferenciadas, temos:

1. Primeira derivada:

$$\sum_{k=1}^{\infty} k \cdot q^{k-1} = \frac{d}{dq} \sum_{k=0}^{\infty} q^k = \frac{1}{(1 - q)^2}$$

2. Segunda derivada:

$$\sum_{k=2}^{\infty} k(k-1) \cdot q^{k-2} = \frac{d^2}{dq^2} \sum_{k=0}^{\infty} q^k = \frac{d^2}{dq^2} \left( \frac{1}{1-q} \right) = \frac{2}{(1-q)^3}$$

Multiplicando por  $q$ , obtemos:

$$\sum_{k=2}^{\infty} k(k-1) \cdot q^{k-1} = \frac{2q}{(1-q)^3}$$

Assim, substituindo na fórmula da variância:

$$\text{Var}(X) = p \cdot \frac{2q}{(1-q)^3} + \frac{1}{p} - \frac{1}{p^2} = \frac{2qp}{p^3} + \frac{1}{p} - \frac{1}{p^2} = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2}$$

Simplificando os termos:

$$\text{Var}(X) = \frac{2q + p - 1}{p^2} = \frac{1 - p}{p^2} = \frac{q}{p^2}$$

### 2.5.3 Exemplo

```
geom <- rgeom(n, p) + 1

barplot(
  table(geom),
  main = paste("Distribuição Geométrica (p =", p, ")"),
  col = "#55a802",
  ylab = "Frequência",
  xlab = "Número de Tentativas"
)
```




Figure 5: Distribuição Geométrica

```
print(paste("Esperança:", mean(geom), " | ", "1 / p = ", round(1 / p, 4)))

## [1] "Esperança: 1.45 | 1 / p = 1.4286"

print(paste("Variância:", round(var(geom), 4), " | ", "q / p^2 = ", round((1 - p) / p^2,
4)))

## [1] "Variância: 0.6542 | q / p^2 = 0.6122"
```

Como podemos ver o experimento do número de tentativas até o primeiro sucesso, seguindo uma distribuição geométrica com parâmetro  $p$ , resulta em uma média e variância empíricas que se aproximam dos valores teóricos  $E(X) = \frac{1}{p}$  e  $\text{Var}(X) = \frac{1-p}{p^2}$ , confirmando as propriedades esperadas da distribuição.

## 2.6 Distribuição Hipergeométrica

### 2.6.1 Esperança

### 2.6.2 Variância

### 2.6.3 Exemplo

## 3 Distribuições Contínuas

Ao contrário das distribuições discretas, as distribuições contínuas modelam variáveis aleatórias que podem assumir um número infinito de valores dentro de um determinado intervalo. Essa característica fundamental implica o uso de cálculo integral para determinar a probabilidade de uma variável aleatória se encontrar em um intervalo específico. A seguir, exploraremos algumas das distribuições contínuas mais proeminentes e amplamente aplicadas no campo da estatística. Como a variável aleatória  $X$  pode assumir qualquer valor não negativo, a probabilidade de  $X$  assumir um valor específico é zero. Em vez disso, as distribuições contínuas são caracterizadas por uma função de densidade de probabilidade (FDP), que descreve a probabilidade de  $X$  cair dentro de um intervalo específico. A integral da FDP sobre um intervalo fornece a probabilidade de  $X$

estar dentro desse intervalo.

### 3.1 Distribuição Exponencial

A distribuição exponencial é uma distribuição contínua que modela o tempo entre (distâncias) eventos em um processo de Poisson. Tendo os eventos independentes e ocorrendo a uma taxa constante, a função de densidade de probabilidade (FDP) é dada por:

$$f(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Com isso, a função de distribuição acumulada (FDA) é:

$$F(x; \lambda) = \mathbb{P}(X \leq x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

#### 3.1.1 Esperança

A esperança da variável  $X$  é dada por:

$$E(X) = \int_0^{\infty} x f(x; \lambda) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

#### 3.1.2 Variância

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = \int_0^{\infty} x^2 f(x; \lambda) dx - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}$$

#### 3.1.3 Exemplo

```
lambda <- 0.5
exp_data <- rexp(n, lambda)
hist(exp_data,
     breaks = 30, probability = TRUE,
     main = paste("Distribuição Exponencial (lambda =", lambda, ")"),
     xlab = "Valor", ylab = "Densidade",
     col = "#55a802", border = "white"
)
curve(dexp(x, lambda), add = TRUE, col = "blue", lwd = 2)
legend("topright", legend = "FDP", col = "blue", lty = 1, lwd = 2)
```

```
print(paste("Esperança:", round(mean(exp_data), 4), " | ", "1 / lambda = ", round(1 /
lambda, 4)))
```

```
## [1] "Esperança: 1.9853 | 1 / lambda = 2"
```

```
print(paste("Variância:", round(var(exp_data), 4), " | ", "1 / lambda^2 = ", round(1 /
lambda^2, 4)))
```

```
## [1] "Variância: 4.0407 | 1 / lambda^2 = 4"
```

Como pode ser visto a média e a variância empíricas da amostra de uma variável aleatória que segue uma distribuição exponencial com parâmetro  $\lambda$  se aproximam dos valores teóricos  $E(X) = \frac{1}{\lambda}$  e  $\text{Var}(X) = \frac{1}{\lambda^2}$ , confirmando as propriedades esperadas da distribuição.

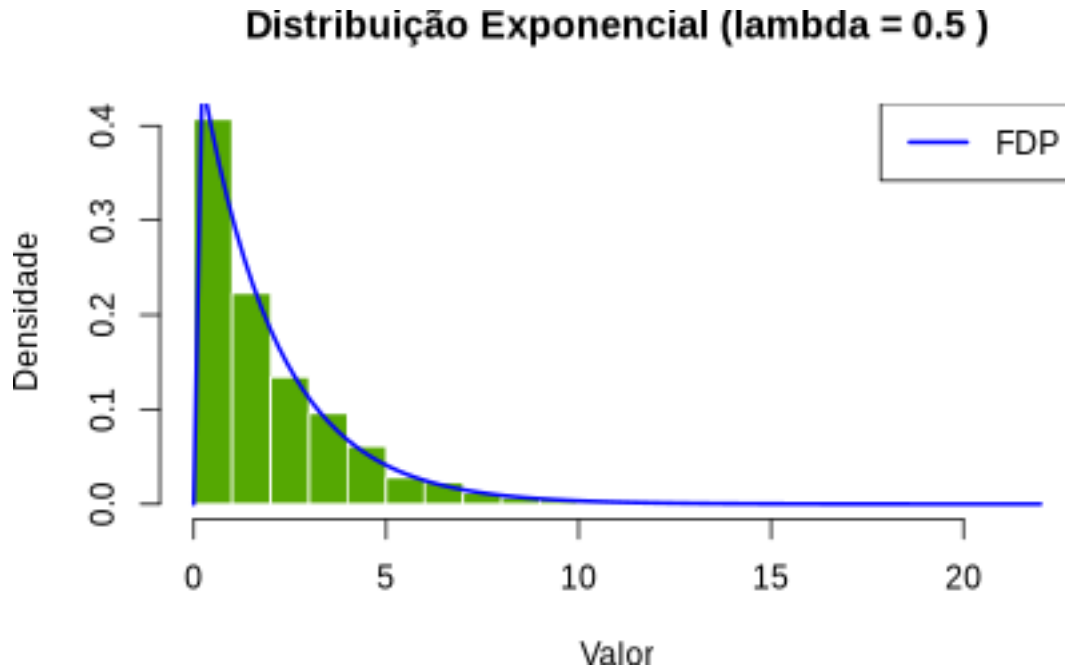


Figure 6: Distribuição Exponencial

### 3.2 Distribuição Gamma

A distribuição Gamma é uma generalização da distribuição Exponencial, utilizada para modelar o **tempo até a ocorrência do  $\alpha$ -ésimo evento** em um processo de Poisson. A função densidade de probabilidade (FDP), na parametrização com taxa  $\beta$ , é:

$$f(x; \alpha, \beta) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}, \quad x \geq 0$$

Quando  $\alpha = 1$ , essa expressão se reduz à distribuição Exponencial com parâmetro  $\beta$ :

$$f(x; 1, \beta) = \beta e^{-\beta x}$$

A função de distribuição acumulada (FDA) é dada pela função gama incompleta regularizada:

$$F(x; \alpha, \beta) = \int_0^x f(t; \alpha, \beta) dt = \frac{\gamma(\alpha, \beta x)}{\Gamma(\alpha)}$$

#### 3.2.1 Esperança

A esperança da variável aleatória  $X$  é:

$$\mathbb{E}(X) = \frac{\alpha}{\beta}$$

#### 3.2.2 Variância

A variância é:

$$\text{Var}(X) = \frac{\alpha}{\beta^2}$$

## 3.2.3 Exemplo

```
alpha <- 2
beta <- 1
gamma_data <- rgamma(n, shape = alpha, scale = 1 / beta)
hist(gamma_data,
     breaks = 30, probability = TRUE,
     main = paste("Distribuição Gamma (alpha =", alpha, ", beta =", beta, ")"),
     xlab = "Valor", ylab = "Densidade",
     col = "#55a802", border = "white"
)
curve(dgamma(x, shape = alpha, scale = 1 / beta), add = TRUE, col = "blue", lwd = 2)
legend("topright", legend = "FDP", col = "blue", lty = 1, lwd = 2)
```




Figure 7: Distribuição Gamma

```
print(paste("Esperança:", round(mean(gamma_data), 4), " | ", "alpha / beta = ",
round(alpha / beta, 4)))
```

```
## [1] "Esperança: 1.9626 | alpha / beta = 2"
```

```
print(paste("Variância:", round(var(gamma_data), 4), " | ", "alpha / beta^2 = ",
round(alpha / beta^2, 4)))
```

```
## [1] "Variância: 1.991 | alpha / beta^2 = 2"
```

Podemos observar que a média e a variância empíricas da amostra de uma variável aleatória que segue uma distribuição Gamma com parâmetros  $\alpha$  e  $\beta$  se aproximam dos valores teóricos  $E(X) = \frac{\alpha}{\beta}$  e  $\text{Var}(X) = \frac{\alpha}{\beta^2}$ , confirmando as propriedades esperadas da distribuição.